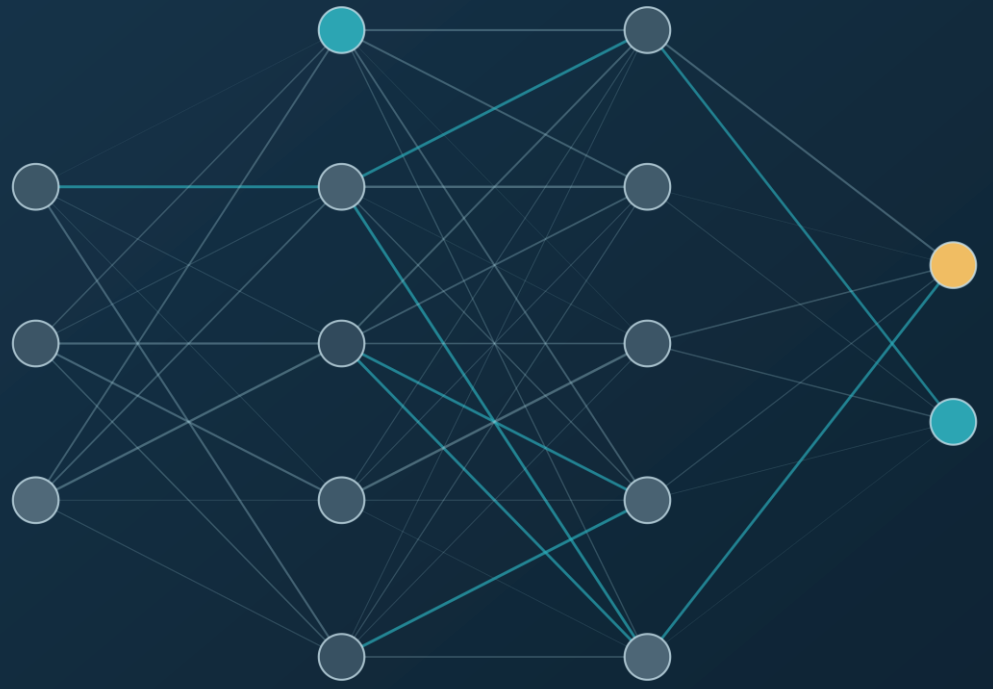
Dentro la rete



Struttura e (un po’ di) matematica di una piccola rete neurale

Francesco Operetto

© Francesco Operetto, 2026 · Licenza CC BY-SA 4.0
Le citazioni di terzi restano dei rispettivi autori e sono escluse dalla licenza.
Grafica e immagini elaborate anche con strumenti di intelligenza artificiale.

Il percorso

Esperimenti nel simulatore e approfondimenti

1 Capacità attuali e agenti 04–06

2 Struttura, attivazioni e profondità 07–18

3 Interpretabilità 19

4 Errore e apprendimento 20–28

5 Softmax e generazione di sequenze 29–31

6 Risultati, rischi e verifica 32–40

7 Approfondimenti e materiali 41–59

Apri il simulatore Dentro la rete

«Qualunque tecnologia sufficientemente avanzata è indistinguibile dalla magia.»

Arthur C. Clarke



«Qualunque tecnologia sufficientemente avanzata è indistinguibile dalla magia.»

Arthur C. Clarke

Conoscere alcuni meccanismi aiuta a valutare potenzialità e limiti.



Il percorso



1 **Capacità attuali e agenti** 04–06

2 Struttura, attivazioni e profondità 07–18

3 Interpretabilità 19

4 Errore e apprendimento 20–28

5 Softmax e generazione di sequenze 29–31

6 Risultati, rischi e verifica 32–40

7 Approfondimenti e materiali 41–59

A che punto siamo? Alcuni esempi

Volti e video sintetici

Modificare un volto, generare un avatar e produrre un video.

- Deepfake in tempo reale
- Avatar video · HeyGen (1)
- Avatar video · HeyGen (2)

Interazione audiovisiva

Un interlocutore sintetico che risponde in tempo reale.

- Dimostrazione Griffin · Tavus

A che punto siamo? Alcuni esempi

Programmazione

Un sito funzionante (una bozza?) da un’unica consegna.

Una richiesta articolata: pagina in italiano, assemblaggio della pizza in 3D, fotografie e animazioni legate allo scorrimento.

- Il risultato
- Il prompt completo

Biologia e neuroscienze

Modelli linguistici genomici hanno generato nuovi genomi di batteriofagi. Alcuni sono stati sintetizzati sperimentalmente; loro combinazioni hanno superato la resistenza di batteri al fago naturale di riferimento.

- Articolo Science

TRIBE v2 predice le risposte cerebrali misurate con fMRI a stimoli visivi, sonori e linguistici.

- TRIBE v2 · Meta

A che punto siamo? Alcuni esempi

Programmazione

Un sito funzionante (una bozza?) da un’unica consegna.

Una richiesta articolata: pagina in italiano, assemblaggio della pizza in 3D, fotografie e animazioni legate allo scorrimento.

- Il risultato
- Il prompt completo

Biologia e neuroscienze

Modelli linguistici genomici hanno generato nuovi genomi di batteriofagi. Alcuni sono stati sintetizzati sperimentalmente; loro combinazioni hanno superato la resistenza di batteri al fago naturale di riferimento.

- Articolo Science

TRIBE v2 predice le risposte cerebrali misurate con fMRI a stimoli visivi, sonori e linguistici.

- TRIBE v2 · Meta

Potenzialità & rischi

Agenti all’opera

Un lavoro da avviare dal vivo

1

Tre ricercatori

Italia, Finlandia e Francia: quattro indicatori, con definizione, anno e fonte.

Agenti all’opera

Un lavoro da avviare dal vivo

1

Tre ricercatori

Italia, Finlandia e Francia: quattro indicatori, con definizione, anno e fonte.

2

Un verificatore

Controllo delle fonti e un solo ciclo di correzione.

Agenti all’opera

Un lavoro da avviare dal vivo

1

Tre ricercatori

Italia, Finlandia e Francia: quattro indicatori, con definizione, anno e fonte.

2

Un verificatore

Controllo delle fonti e un solo ciclo di correzione.

3

Un analista e il coordinatore

Dati in Excel, grafici con unità separate e una sintesi in Word.

Prompt completo per la dimostrazione

Il percorso



1 Capacità attuali e agenti 04–06

2 **Struttura, attivazioni e profondità** 07–18

3 Interpretabilità 19

4 Errore e apprendimento 20–28

5 Softmax e generazione di sequenze 29–31

6 Risultati, rischi e verifica 32–40

7 Approfondimenti e materiali 41–59

AI, machine learning, deep learning

Intelligenza artificiale

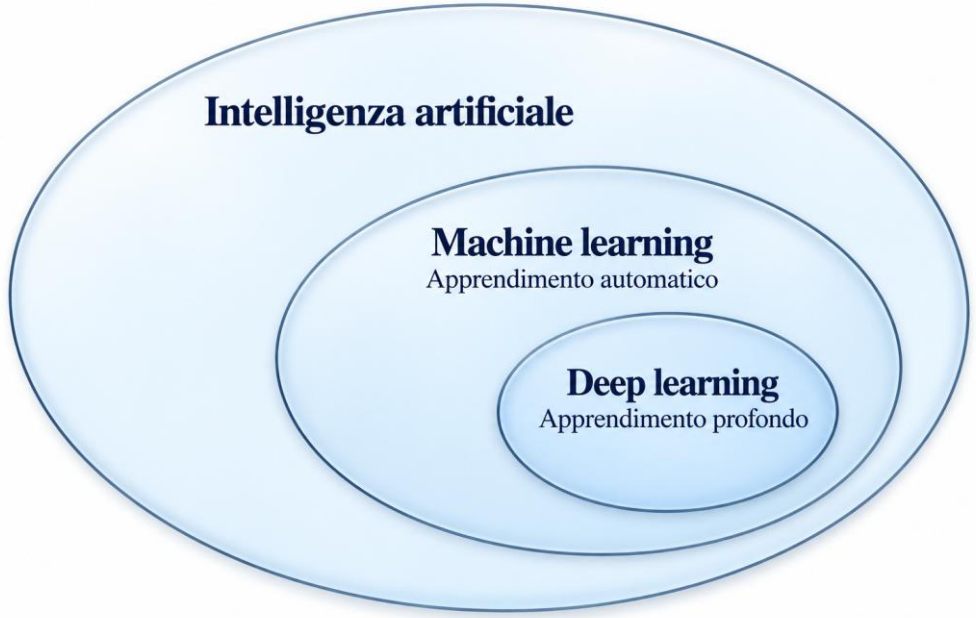
Sistemi che svolgono compiti associati ad attività cognitive umane.

Machine learning

Un approccio all'AI che ricava dai dati regolarità utili a svolgere un compito.

Deep learning

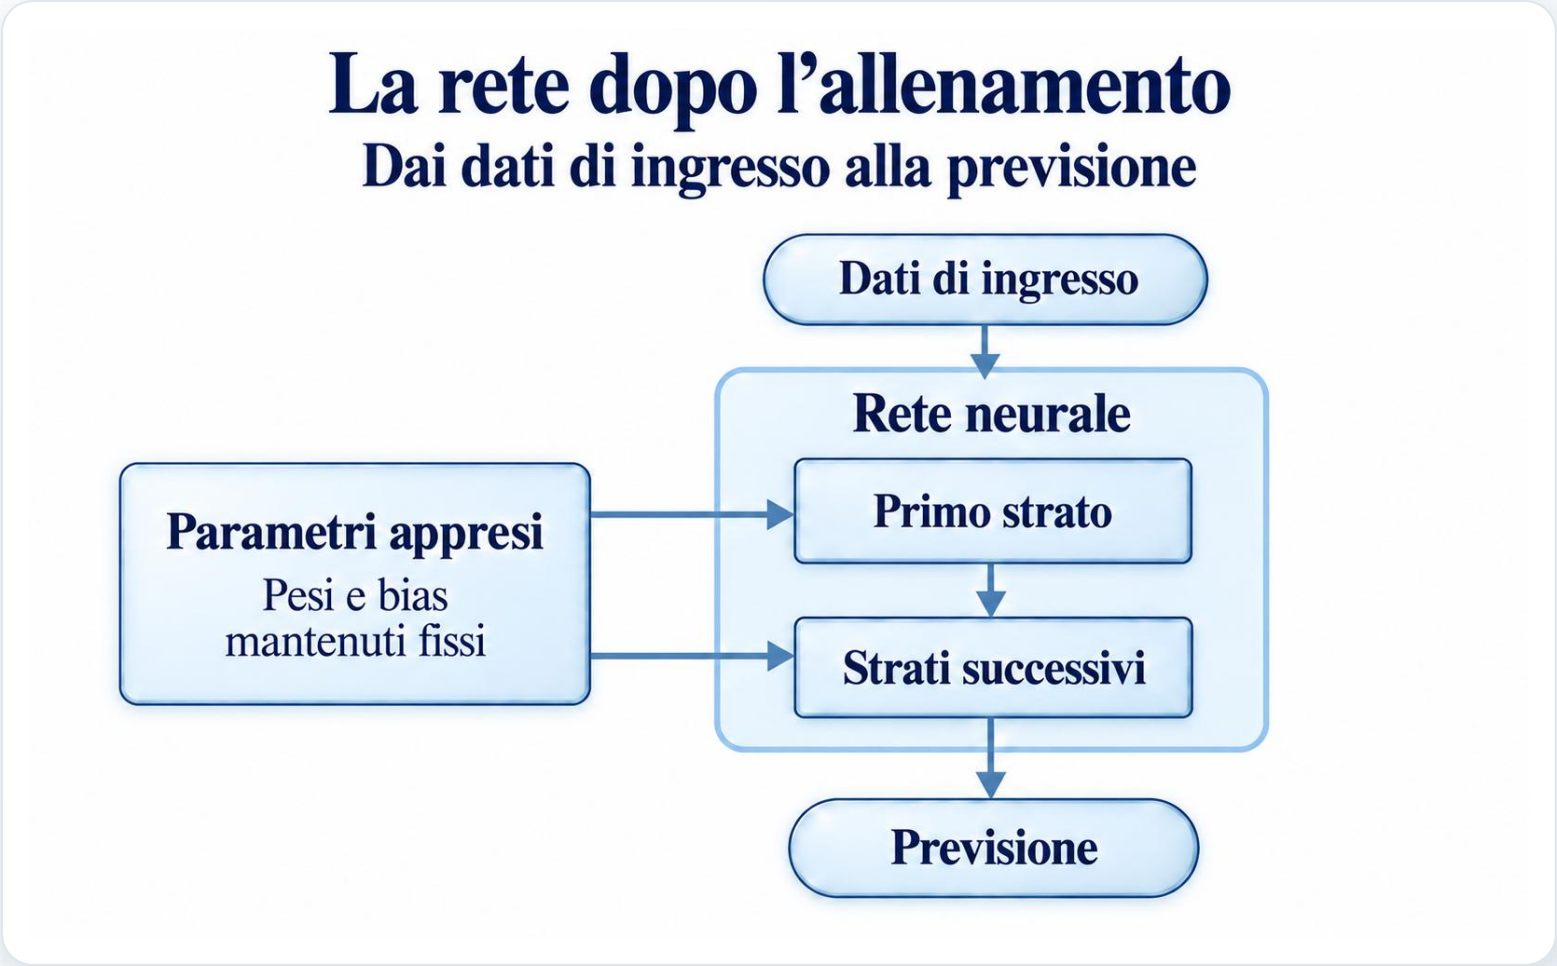
Una famiglia di metodi di machine learning basata su reti neurali con più strati.



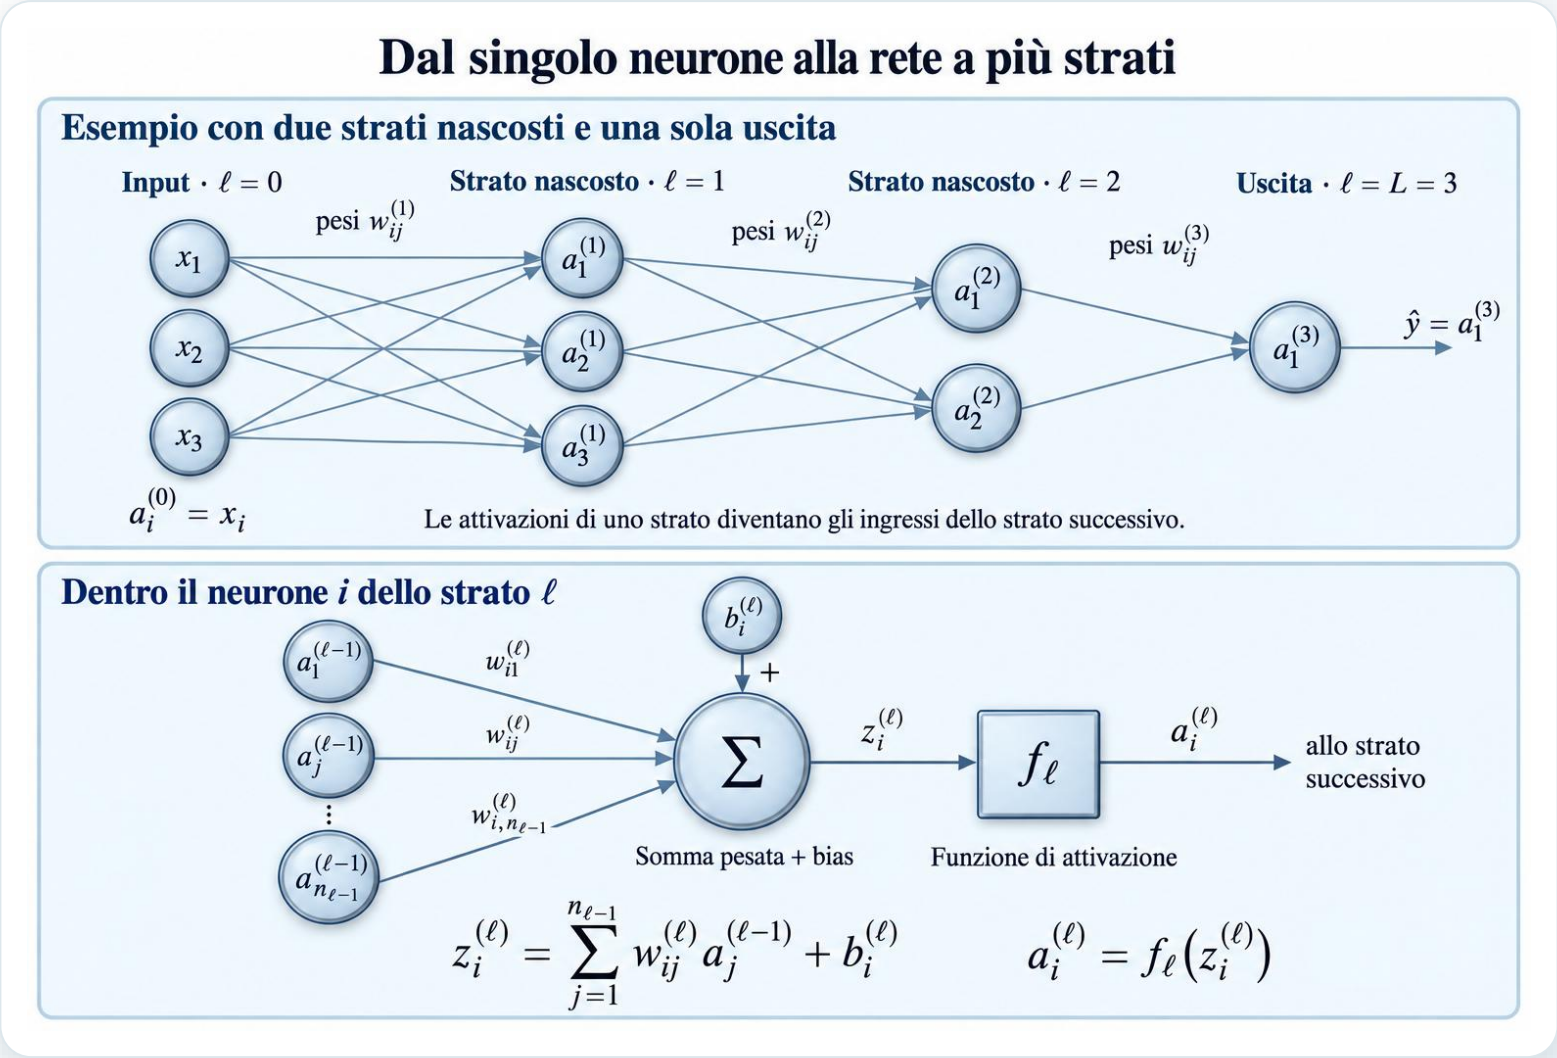
L’apprendimento supervisionato



La rete dopo l’allenamento



La struttura della rete



Il calcolo di un neurone

Somma pesata e bias

$$z_i^{(\ell)} = \sum_{j=1}^{n_{\ell-1}} w_{ij}^{(\ell)}\, a_j^{(\ell-1)} + b_i^{(\ell)}$$



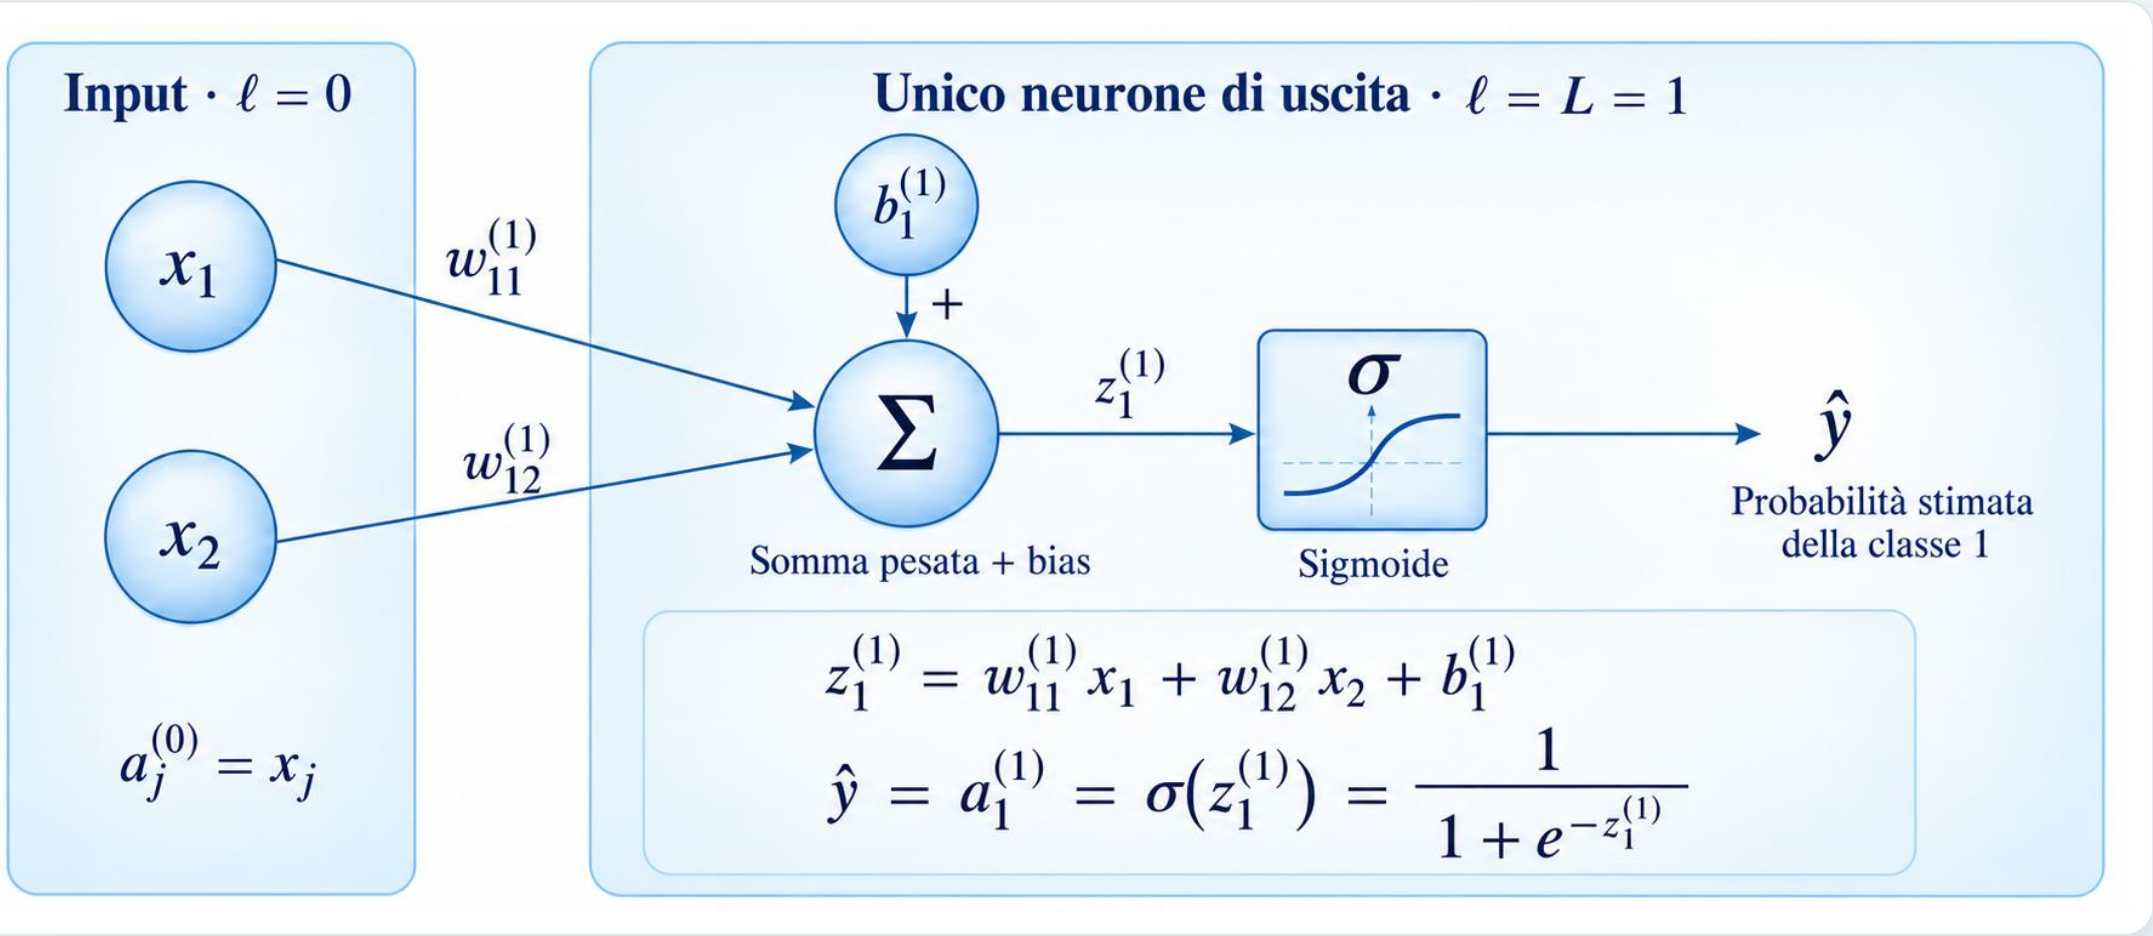
Funzione di attivazione

$$a_i^{(\ell)} = f_\ell(z_i^{(\ell)})$$

Le attivazioni di uno strato diventano gli ingressi dello strato successivo.

Una rete senza strati nascosti

Due input e un'unica uscita sigmoide

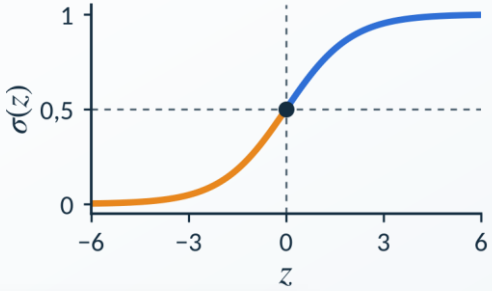


Il confine tra le due classi

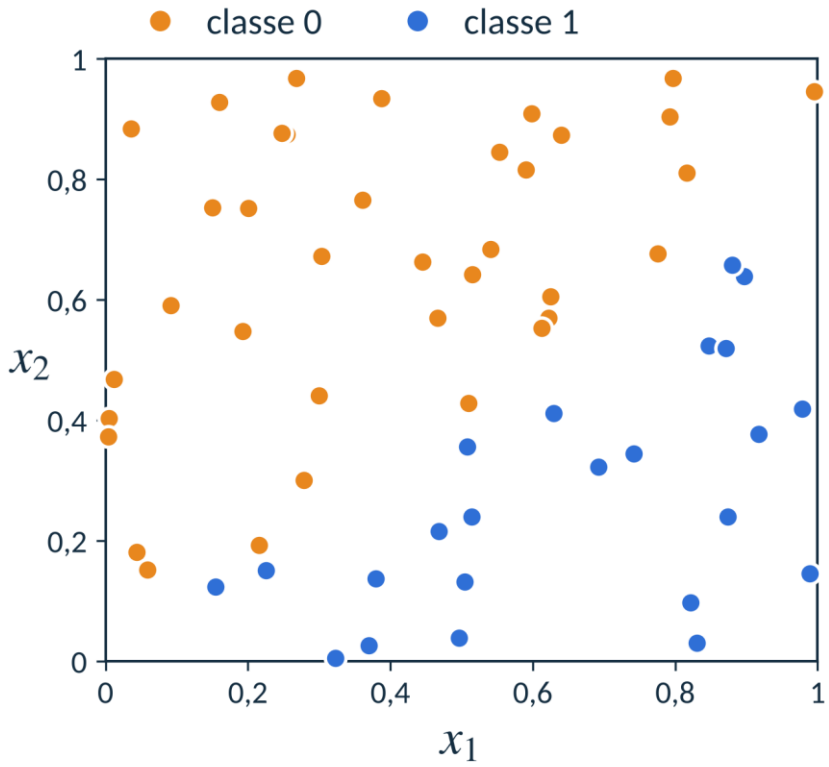
Una rete senza strati nascosti, con uscita sigmoide

La decisione

La rete sceglie la classe 1 quando $\hat{y} \geq 0{,}5$. La sigmoide è crescente e vale 0,5 quando il suo argomento è 0, quindi:



$$\hat{y} \geq 0{,}5 \quad \Leftrightarrow \quad z_1^{(1)} \geq 0$$

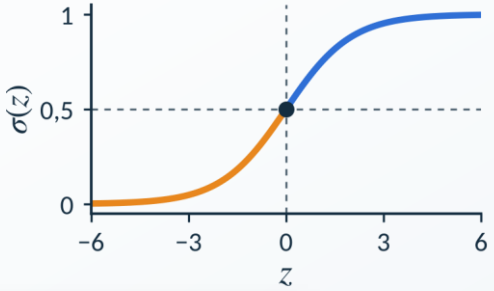


Il confine tra le due classi

Una rete senza strati nascosti, con uscita sigmoide

La decisione

La rete sceglie la classe 1 quando $\hat{y} \geq 0{,}5$. La sigmoide è crescente e vale 0,5 quando il suo argomento è 0, quindi:

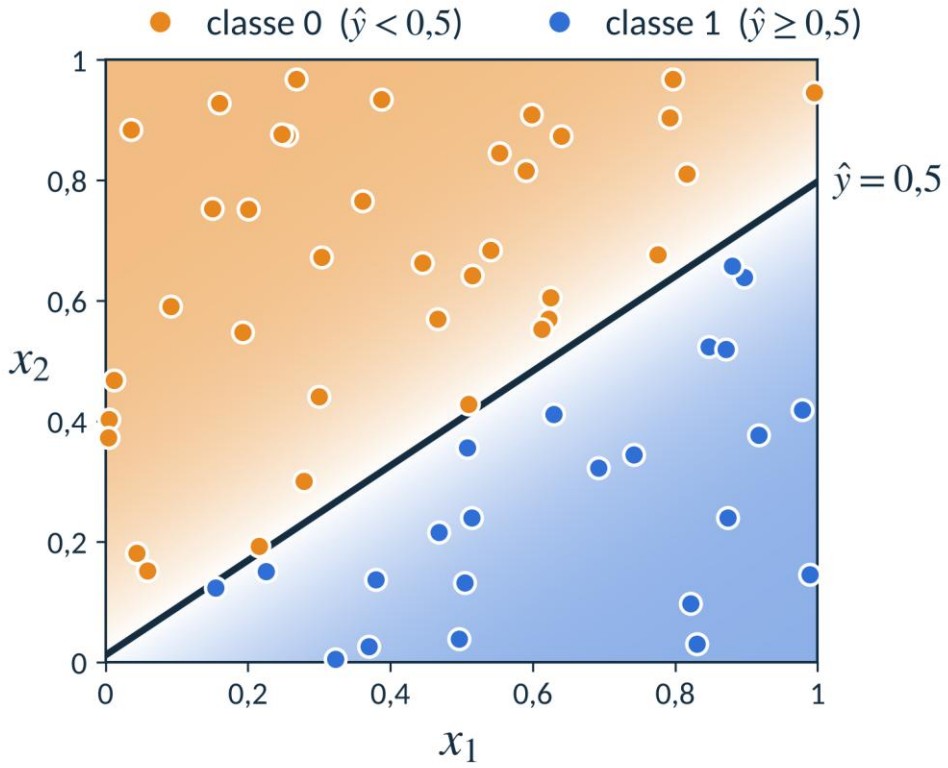


$$\hat{y} \geq 0{,}5 \quad \Leftrightarrow \quad z_1^{(1)} \geq 0$$

Il confine è formato dai punti in cui $\hat{y} = 0{,}5$:

$$w_{11}^{(1)} x_1 + w_{12}^{(1)} x_2 + b_1^{(1)} = 0 \rightarrow \textbf{una retta}$$

Con strati nascosti la soglia di decisione è la stessa, ma $z_1^{(L)}$ può dipendere dagli input in modo non lineare: il confine allora può curvarsi.



Perché serve la non linearità?

Senza attivazioni non lineari, comporre più strati affini produce ancora una trasformazione affine.

$$W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2)$$

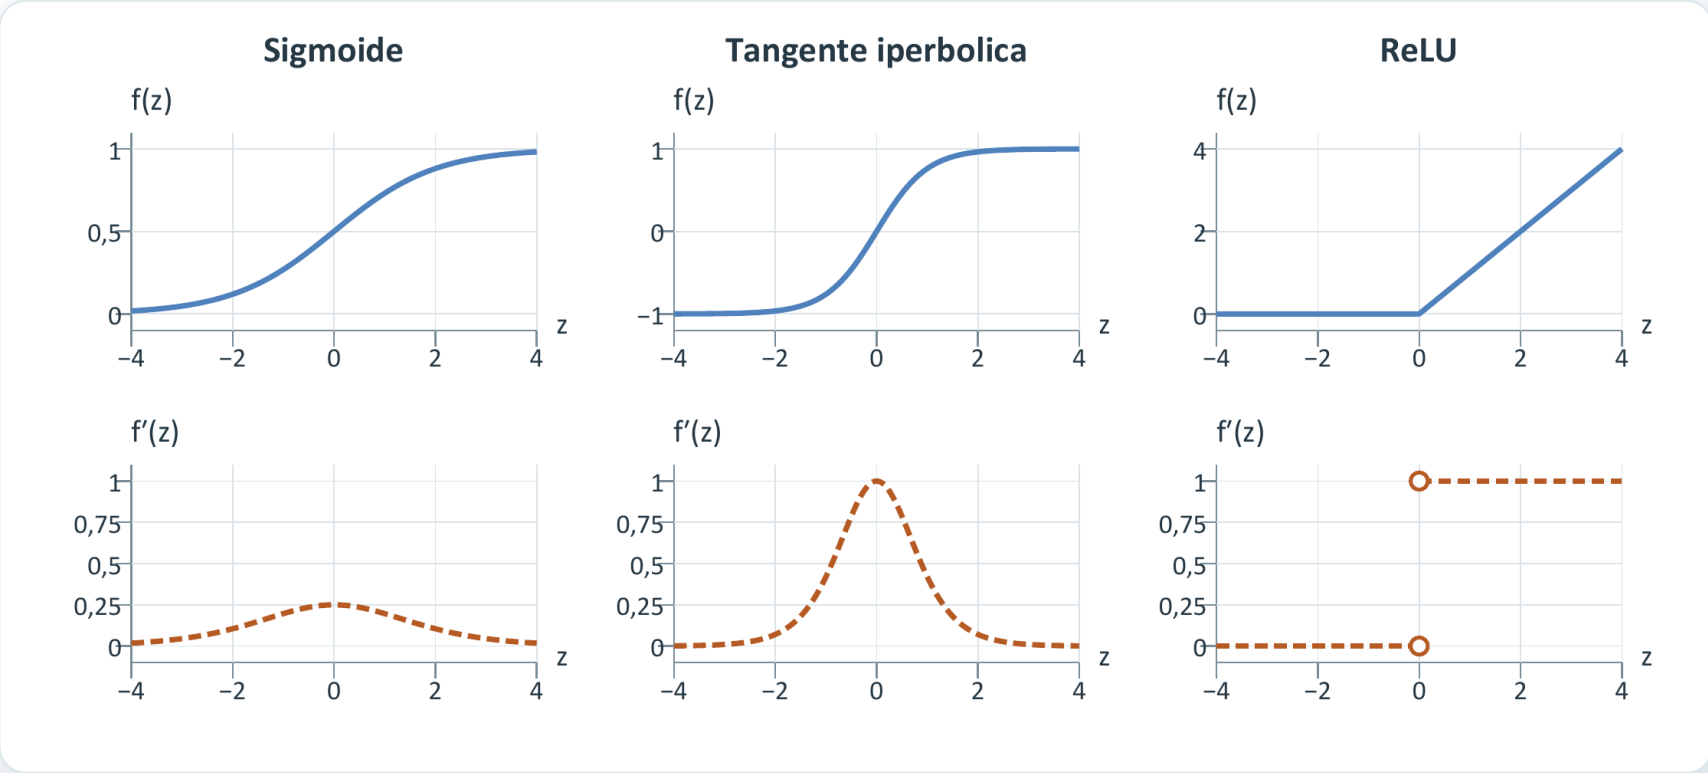
Perché serve la non linearità?

Senza attivazioni non lineari, comporre più strati affini produce ancora una trasformazione affine.

$$W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2)$$

La non linearità permette di ampliare la classe delle funzioni rappresentabili.

Alcune funzioni di attivazione



Le derivate vicine a zero possono attenuare il gradiente durante l'allenamento.

Nella pratica. Negli strati nascosti delle reti profonde attuali si usano soprattutto la ReLU e sue varianti lisce (in particolare GELU e SiLU); tanh e sigmoide restano utili per capire i meccanismi e si usano ancora in alcune architetture.

Attivazioni e derivate

Sigmoide

$$\sigma(z) = \frac{1}{1 + e^{-z}} \qquad \sigma'(z) = \sigma(z)(1 - \sigma(z))$$

Tanh

$$\tanh(z) = \frac{e^{z} - e^{-z}}{e^{z} + e^{-z}} \qquad \tanh'(z) = 1 - \tanh^{2}(z)$$

ReLU

$$f(z) = \max(0, z) \qquad f'(z) = 0 \text{ se } z < 0; \quad 1 \text{ se } z > 0$$

Sigmoide e tanh saturano. ReLU ha derivata nulla per pre-attivazioni negative.
In zero ReLU non è derivabile: l'algoritmo adotta convenzionalmente il valore 0.

Approssimazione universale

In teoria, un solo strato nascosto può bastare, se può avere una larghezza sufficientemente grande.

Con un’attivazione continua non polinomiale, bias nello strato nascosto e uscita lineare, la rete può approssimare arbitrariamente bene ogni funzione continua su un compatto.

Enunciato con la notazione della rete

Leshno, Lin, Pinkus e Schocken · 1993

Perché allora usare più strati?

Efficienza della rappresentazione

Per alcune famiglie di funzioni, la profondità permette di usare molti meno neuroni rispetto a una rete poco profonda.

Esistenza, allenamento, generalizzazione

L’esistenza di una rete adatta non garantisce che l’allenamento ne trovi i parametri, né che funzioni su dati nuovi.

↗ Telgarsky · Benefits of depth in neural networks

Il percorso



1 Capacità attuali e agenti 04–06

2 Struttura, attivazioni e profondità 07–18

3 **Interpretabilità** 19

4 Errore e apprendimento 20–28

5 Softmax e generazione di sequenze 29–31

6 Risultati, rischi e verifica 32–40

7 Approfondimenti e materiali 41–59

Che cosa ha imparato la rete?

Dalle mappe delle attivazioni all'interpretabilità

Le mappe rendono visibili le risposte dei singoli neuroni. Nelle reti più complesse, capire come queste attività contribuiscano alle decisioni del modello resta una sfida per la ricerca.

↗ Una memoria di lavoro per Claude

↗ Una direzione associata al rifiuto

↗ Una rappresentazione del dolore

↗ Il problema del «salmone morto»

Si rischia di attribuire spiegazioni plausibili anche alle attivazioni di reti mai allenate!

Il percorso



1 Capacità attuali e agenti 04–06

2 Struttura, attivazioni e profondità 07–18

3 Interpretabilità 19

4 **Errore e apprendimento** 20–28

5 Softmax e generazione di sequenze 29–31

6 Risultati, rischi e verifica 32–40

7 Approfondimenti e materiali 41–59

La funzione di errore

Sul singolo esempio

Errore quadratico

$$E = \frac{1}{2}(\hat{y} - y)^2$$

$\hat{y} = a_1^{(L)}$ è l'uscita numerica della rete, y il valore bersaglio.
Si usa, per esempio, nella regressione e può essere usato nel caso binario.

La loss valuta l'uscita prima dell'eventuale decisione a soglia.

Entropia incrociata

Una classe corretta per ogni esempio

$$E = -\sum_{i=1}^{K} t_i \ln p_i = -\ln p_c$$

Bersaglio one-hot: $t_i = 1$ per la classe corretta c, $t_i = 0$ per le altre.

Conta la probabilità che il modello assegna alla classe corretta.

Più bassa è quella probabilità, maggiore è la penalità.

La stessa quantità descrive la «sorpresa» dell'esito secondo il modello.

Probabilità assegnata ed errore

Probabilità della classe corretta	Errore
0,9	0,105
0,5	0,693
0,01	4,605

$E = 0$ se $p_c = 1$; $E \to +\infty$ per $p_c \to 0^+$

L’errore su un insieme di esempi

θ raccoglie tutti i parametri della rete: pesi e bias.
Su N esempi si considera la media degli errori.

$$\overline{E}(\theta) = \frac{1}{N}\sum_{r=1}^{N} E_r\,(\theta)$$

L’allenamento cerca parametri che riducano questa quantità.

Allenamento e generalizzazione

Dati di allenamento

Servono per aggiornare pesi e bias.

Dati di validazione

Permettono di osservare il comportamento su esempi non usati per quegli aggiornamenti.

Allenamento e generalizzazione

Dati di allenamento

Servono per aggiornare pesi e bias.

Dati di validazione

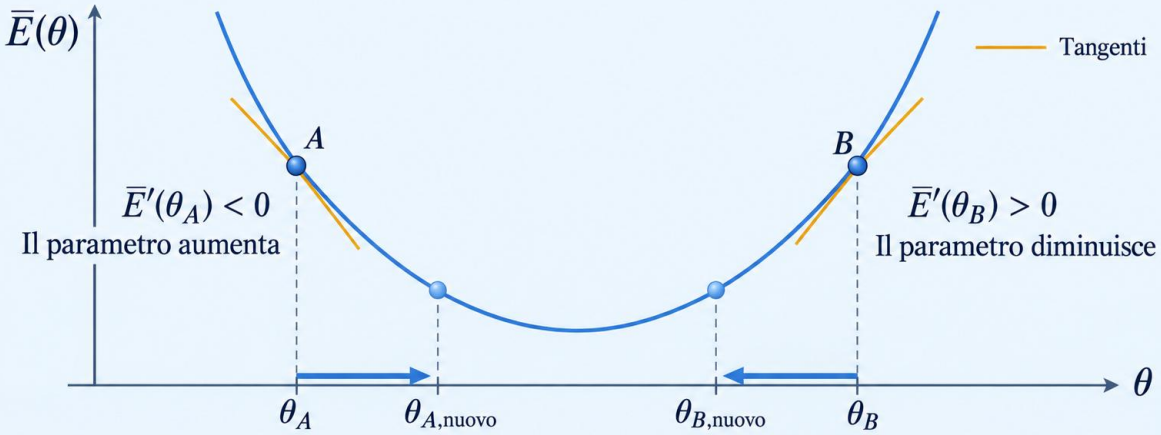
Permettono di osservare il comportamento su esempi non usati per quegli aggiornamenti.

Un errore basso sui dati già visti non basta a dimostrare che la rete generalizzi.

Discesa del gradiente: una sola variabile

La discesa del gradiente con un solo parametro

Due esempi di aggiornamento sullo stesso grafico

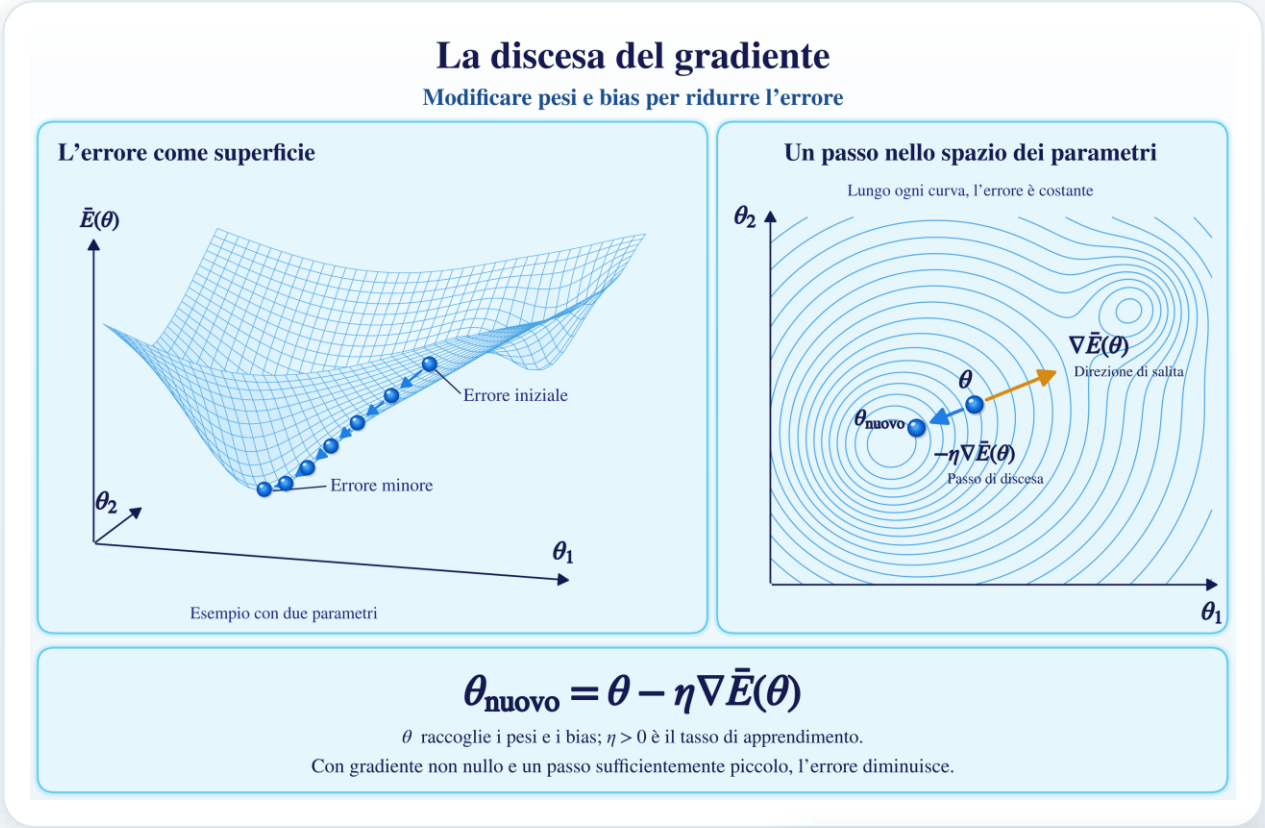


$$\theta_{\text{nuovo}} = \theta - \eta \overline{E}'(\theta)$$

$\eta > 0$ è il tasso di apprendimento.
Con derivata non nulla e un passo sufficientemente piccolo, l'errore diminuisce.

$$\theta_{\text{nuovo}} = \theta - \eta \overline{E}'(\theta)$$

Discesa del gradiente: più parametri



$$\theta_{\text{nuovo}} = \theta - \eta\nabla\overline{E}(\theta)$$

$$\theta_{j,\text{nuovo}} = \theta_j - \eta\frac{\partial\overline{E}}{\partial\theta_j}$$

La discesa del gradiente nella pratica

Minimi locali e selle

Nelle reti grandi i minimi locali con errore alto spesso non sono il problema principale: rallentano di più selle e regioni quasi piatte, da cui aiuta ad allontanarsi il rumore che nasce dall'usare pochi esempi per ogni aggiornamento.

Una discesa più evoluta

Il momento combina i gradienti recenti, metodi come Adam regolano il passo per ciascun parametro e il tasso di apprendimento varia durante l'allenamento.

Nelle reti piccole

Nel simulatore l'allenamento può fermarsi in un minimo scadente: disattiva «Seme fisso» e premi «Riparti», oppure aggiungi neuroni.

Come si calcola il gradiente?

Il calcolo si basa sulla derivazione di funzioni composte («regola della catena») a più variabili

Il segnale d’errore misura la sensibilità della loss alla pre-attivazione.

$$\delta_i^{(\ell)} = \frac{\partial E}{\partial z_i^{(\ell)}}$$

$$\frac{\partial E}{\partial w_{ij}^{(\ell)}} = \delta_i^{(\ell)} a_j^{(\ell-1)}, \qquad \frac{\partial E}{\partial b_i^{(\ell)}} = \delta_i^{(\ell)}$$

Come si calcola il gradiente?

Il calcolo si basa sulla derivazione di funzioni composte («regola della catena») a più variabili

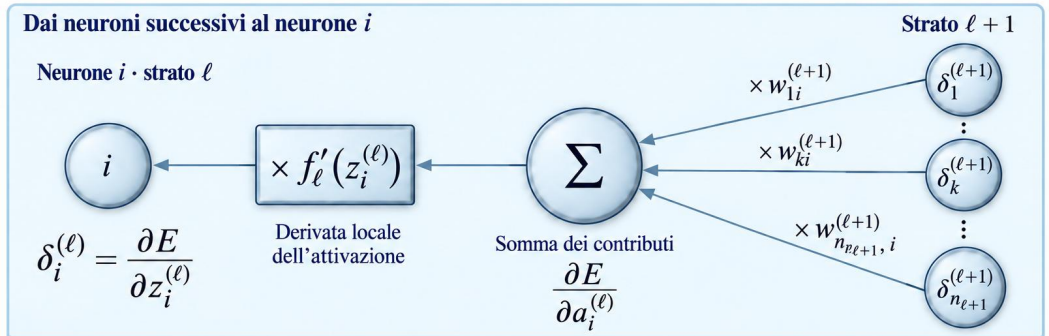
Il segnale d'errore misura la sensibilità della loss alla pre-attivazione.

$$\delta_i^{(\ell)} = \frac{\partial E}{\partial z_i^{(\ell)}}$$

$$\frac{\partial E}{\partial w_{ij}^{(\ell)}} = \delta_i^{(\ell)} a_j^{(\ell-1)}, \qquad \frac{\partial E}{\partial b_i^{(\ell)}} = \delta_i^{(\ell)}$$

Come si calcola δ in uno strato nascosto

$$\delta_{\text{neurone}} = f'(z_{\text{neurone}}) \cdot \sum_{\text{successivi}} (w \cdot \delta_{\text{successivo}})$$



$$\delta_i^{(\ell)} = f'_\ell(z_i^{(\ell)}) \sum_{k=1}^{n_{\ell+1}} w_{ki}^{(\ell+1)} \delta_k^{(\ell+1)}$$

Le frecce indicano il calcolo delle derivate, non nuove connessioni della rete.

Si parte dall'uscita – calcolo diretto – e si procede all'indietro.

Derivazione e formula per gli strati nascosti e strato finale

Backpropagation

Rumelhart, Hinton e Williams

Nature, 1986

Il percorso



1 Capacità attuali e agenti 04–06

2 Struttura, attivazioni e profondità 07–18

3 Interpretabilità 19

4 Errore e apprendimento 20–28

5 **Softmax e generazione di sequenze** 29–31

6 Risultati, rischi e verifica 32–40

7 Approfondimenti e materiali 41–59

Il problema multiclasse e la softmax

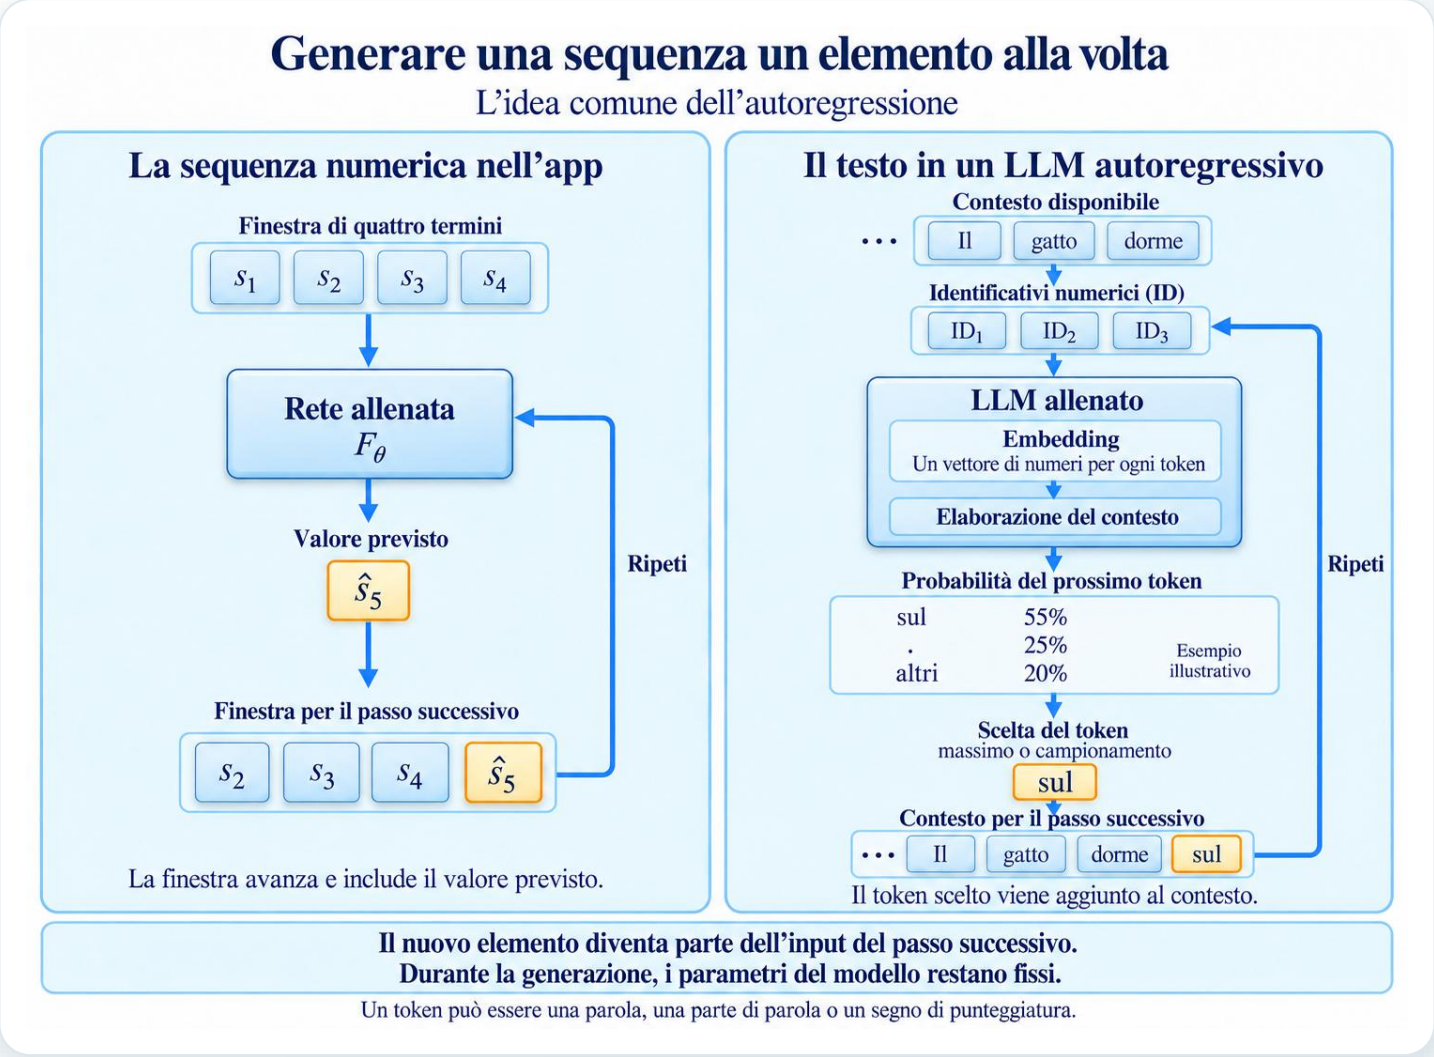
I logits z_i sono le pre-attivazioni di uscita.
La softmax li trasforma in una distribuzione sulle classi.

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}, \qquad i = 1, \dots, K$$

$$p_i > 0, \qquad \sum_{i=1}^{K} p_i = 1$$

Una decisione semplice sceglie la classe con probabilità maggiore.
Le probabilità del modello potrebbero non riflettere l'effettiva attendibilità della previsione.

Generare una sequenza un elemento alla volta



L’analogia con i Large Language Model

1

Input numerici

I token diventano identificativi e poi vettori numerici, gli embedding.

L’analogia con i Large Language Model

1

Input numerici

I token diventano identificativi e poi vettori numerici, gli embedding.

2

Elaborazione del contesto

Il modello assegna probabilità ai possibili token successivi.

L’analogia con i Large Language Model

1

Input numerici

I token diventano identificativi e poi vettori numerici, gli embedding.

2

Elaborazione del contesto

Il modello assegna probabilità ai possibili token successivi.

3

Generazione autoregressiva

Il token scelto entra nel contesto del passo seguente. Durante la generazione ordinaria, i pesi restano fissi.

Il percorso



1 Capacità attuali e agenti 04–06

2 Struttura, attivazioni e profondità 07–18

3 Interpretabilità 19

4 Errore e apprendimento 20–28

5 Softmax e generazione di sequenze 29–31

6 **Risultati, rischi e verifica** 32–40

7 Approfondimenti e materiali 41–59

Rischi e comunicazione del rischio

Incidenti e analisi tecniche

- Incidente Hugging Face · rapporto
- Incidente bacheche violate · rapporto
- Siti governativi · analisi Transluce

Durante una ricerca su registrazioni di divorzi in Canada, attività attribuite ad agenti AI hanno incluso tentativi di intrusione.

- Sviluppo di armi e minacce cyber · rapporto Anthropic

Rischi e comunicazione del rischio

Incidenti e analisi tecniche

- Incidente Hugging Face · rapporto
- Incidente bacheche violate · rapporto
- Siti governativi · analisi Transluce

Durante una ricerca su registrazioni di divorzi in Canada, attività attribuite ad agenti AI hanno incluso tentativi di intrusione.

- Sviluppo di armi e minacce cyber · rapporto Anthropic

Scenari e comunicazione commerciale

- Paperclip maximizer · Nick Bostrom
- Auto-miglioramento · Anthropic

«Jacob ha ragione: crediamo davvero, sinceramente, che l'IA possa uccidere tutti gli esseri umani! Personalmente ritengo che la probabilità sia superiore al 10% entro il prossimo decennio. Credo che Anthropic stia facendo del suo meglio, ma non abbiamo ancora un piano per risolvere l'allineamento della superintelligenza, e non è chiaro che siamo sulla buona strada per averlo.»

Evan Hubinger (Anthropic) · X, 9 settembre 2026

In risposta a Jacob Coxon, secondo cui chi costruisce l'IA crede sinceramente che possa ucciderci tutti entro la fine del decennio, e non si tratta di una trovata pubblicitaria. Traduzione dall'inglese · post originale

Rischi e comunicazione del rischio

Incidenti e analisi tecniche

- Incidente Hugging Face · rapporto
- Incidente bacheche violate · rapporto
- Siti governativi · analisi Transluce

Durante una ricerca su registrazioni di divorzi in Canada, attività attribuite ad agenti AI hanno incluso tentativi di intrusione.

- Sviluppo di armi e minacce cyber · rapporto Anthropic

Quanto è rischio documentato, quanto è marketing della paura?
Si parla molto meno di concentrazione di potere e rischi culturali.

Scenari e comunicazione commerciale

- Paperclip maximizer · Nick Bostrom
- Auto-miglioramento · Anthropic

«Jacob ha ragione: crediamo davvero, sinceramente, che l'IA possa uccidere tutti gli esseri umani! Personalmente ritengo che la probabilità sia superiore al 10% entro il prossimo decennio. Credo che Anthropic stia facendo del suo meglio, ma non abbiamo ancora un piano per risolvere l'allineamento della superintelligenza, e non è chiaro che siamo sulla buona strada per averlo.»

Evan Hubinger (Anthropic) · X, 9 settembre 2026

In risposta a Jacob Coxon, secondo cui chi costruisce l'IA crede sinceramente che possa ucciderci tutti entro la fine del decennio, e non si tratta di una trovata pubblicitaria. Traduzione dall'inglese · post originale

Quando la plausibilità sostituisce la verifica

«Epistemia»: basta che sembri convincente



Scambiare la plausibilità
per un criterio di realtà.

- Il termine nella raccolta della Crusca
- Articolo del prof. W. Quattrociocchi
- Un caso di cronaca: l’inchiesta CNN sul rapporto militare errato (fonti anonime)

Completare un compito vs imparare

Il risultato consegnato non misura da solo l’apprendimento.

Uno studio su 26.811 studenti cinesi riporta un miglioramento nei compiti a casa e un peggioramento nelle prove senza aiuti, soprattutto fra chi delega il lavoro all’AI.

Studio osservazionale, pubblicato come discussion paper.
Esiste anche un utilizzo didattico dell’AI che porti benefici?

↗ Strömberg, Lei e Wu · CEPR Discussion Paper 21577

Sistemi AI nella ricerca matematica

Costruzioni, algoritmi e controlli automatici

593

sfere in dimensione 11

AlphaEvolve trova una configurazione: un nuovo limite inferiore al kissing number, non il massimo esatto.

48

moltiplicazioni scalari

Un algoritmo per matrici complesse 4×4.

Cap set e online bin packing

FunSearch produce nuove costruzioni e nuove euristiche, valutate con programmi di controllo.

↗ AlphaEvolve · 2025

↗ FunSearch · 2023–2024

Dimostrazioni, formalizzazioni, revisioni

Situazione e fonti consultate il 17 ottobre 2026

Erdős 124

Una dimostrazione formalizzata della prima formulazione del problema. La pagina distingue due domande.

↗ Pagina del problema

Gruppi non sofici e rigidità di Connes

Risultati presentati con materiali e certificati nel repository degli autori.

↗ Repository ten-proofs

Il catalogo openai/math e la revisione pubblica

Il 7 ottobre: tre ritiri legati a un errore di segno e ulteriori correzioni.

↗ Cronologia degli aggiornamenti

Che cosa certifica una prova in Lean?

Il verificatore controlla la dimostrazione dell’enunciato formalizzato, sotto le ipotesi dichiarate.

Che cosa certifica una prova in Lean?

Il verificatore controlla la dimostrazione dell’enunciato formalizzato, sotto le ipotesi dichiarate.

Quell’enunciato esprime davvero il problema che volevamo risolvere?

Che cosa certifica una prova in Lean?

Il verificatore controlla la dimostrazione dell’enunciato formalizzato, sotto le ipotesi dichiarate.

Quell’enunciato esprime davvero il problema che volevamo risolvere?

Il caso Navier–Stokes: un annuncio di dimostrazione e una critica alla corrispondenza fra testo matematico e formalizzazione.

↗ Annuncio e materiali

↗ Critica di Bastounis, Circelli e Hansen

L’AI potrà introdurre nuovi paradigmi scientifici?

> *«L'intelligenza artificiale può generare scoperte scientifiche rivoluzionarie del tipo che richiede **salti creativi** e **ridefinisce la nostra comprensione** della natura e dell'universo, come la relatività, l'evoluzione o la meccanica quantistica?»*

L’AI potrà introdurre nuovi paradigmi scientifici?

> *«L'intelligenza artificiale può generare scoperte scientifiche rivoluzionarie del tipo che richiede **salti creativi** e **ridefinisce la nostra comprensione** della natura e dell'universo, come la relatività, l'evoluzione o la meccanica quantistica?»*

Il «test di Einstein»

Con a disposizione solo i dati fino al 1911, un’AI riscoprirebbe la relatività?
Di quali strumenti dovremmo dotarla per farlo?

↗ La proposta del test

↗ Un’analisi delle capacità attuali dell’AI

Un flusso di lavoro con due istanze AI

1

Redattore + interazioni

Una bozza guidata.

Un flusso di lavoro con due istanze AI

1

Redattore + interazioni

Una bozza guidata.

2

Revisore + interazioni

Controllo critico di contenuto, calcoli, fonti e comprensibilità, report al redattore

Un flusso di lavoro con due istanze AI

1. **Redattore + interazioni**

   Una bozza guidata.

2. **Revisore + interazioni**

   Controllo critico di contenuto, calcoli, fonti e comprensibilità, report al redattore

3. **Redattore + interazioni**

   Il redattore valuta le obiezioni e motiva le modifiche, report al revisore

Un flusso di lavoro con due istanze AI

1. **Redattore + interazioni**
   Una bozza guidata.
2. **Revisore + interazioni**
   Controllo critico di contenuto, calcoli, fonti e comprensibilità, report al redattore
3. **Redattore + interazioni**
   Il redattore valuta le obiezioni e motiva le modifiche, report al revisore
4. **Si ripete dal punto 2**

I prompt dell’esempio sul Superenalotto

La verifica resta parte del lavoro

Possono discutere la terza cifra significativa di un dato e non vedere che manca un pezzo di introduzione!

La verifica resta parte del lavoro

Possono discutere la terza cifra significativa di un dato e non vedere che manca un pezzo di introduzione!

Le revisioni di solito convergono…

La verifica resta parte del lavoro

Possono discutere la terza cifra significativa di un dato e non vedere che manca un pezzo di introduzione!

Le revisioni di solito convergono…
… ma non sempre dove dovrebbero!

Il percorso



1 Capacità attuali e agenti 04–06

2 Struttura, attivazioni e profondità 07–18

3 Interpretabilità 19

4 Errore e apprendimento 20–28

5 Softmax e generazione di sequenze 29–31

6 Risultati, rischi e verifica 32–40

7 **Approfondimenti e materiali** 41–59

Approfondimenti e materiali

- Teorema di approssimazione universale 40
- Batch, SGD e mini-batch 41
- Backpropagation: derivate e strati nascosti 42–45
- Backpropagation: lo strato di uscita 46
- Verificare una dimostrazione, valutare un testo 47–50
- Prompt della dimostrazione con gli agenti 51–54
- Prompt del flusso redattore / revisore 55–56
- Bibliografia 57

Approssimazione universale: l’enunciato

Sia $f_1: \mathbb{R} \to \mathbb{R}$ continua e non polinomiale e K un compatto in uno spazio reale di dimensione n_0. Consideriamo reti con uno strato nascosto e uscita lineare:

$$F_\theta(x) = \sum_{j=1}^{n_1} w_{1j}^{(2)} \, f_1\Big(\sum_{k=1}^{n_0} w_{jk}^{(1)} \, x_k + b_j^{(1)}\Big)$$

Per ogni funzione continua $g: K \to \mathbb{R}$ e ogni $\varepsilon > 0$, esistono una larghezza finita n_1 e parametri θ tali che

$$\sup_{x \in K} |F_\theta(x) - g(x)| < \varepsilon$$

↗ Leshno, Lin, Pinkus e Schocken · teorema 1

Su quali esempi si calcola il gradiente?

Batch gradient descent

Un aggiornamento usa tutti gli esempi di allenamento.

Stochastic gradient descent

Nella variante per singolo esempio, ogni aggiornamento usa un solo esempio.

Mini-batch

Ogni aggiornamento usa un piccolo gruppo di esempi.

Il random reshuffling rimescola gli esempi a ogni epoca; può accompagnare i mini-batch.

Backpropagation

$$z_i^{(\ell)} = \sum_{j=1}^{n_{\ell-1}} w_{ij}^{(\ell)}\, a_j^{(\ell-1)} + b_i^{(\ell)}$$

La struttura della rete.

$$\delta_i^{(\ell)} = \frac{\partial E}{\partial z_i^{(\ell)}}$$

La definizione di segnale d’errore.

$$\frac{\partial E}{\partial w_{ij}^{(\ell)}} = \frac{\partial E}{\partial z_i^{(\ell)}} \frac{\partial z_i^{(\ell)}}{\partial w_{ij}^{(\ell)}} = \delta_i^{(\ell)} a_j^{(\ell-1)}$$

$$\frac{\partial E}{\partial b_i^{(\ell)}} = \delta_i^{(\ell)}$$

L’utilità dei segnali di errore.

Backpropagation: gli strati nascosti

Per attivazioni applicate componente per componente:

$$\delta_i^{(\ell)} = \frac{\partial E}{\partial a_i^{(\ell)}} f_\ell'(z_i^{(\ell)})$$

La «regola della catena» nel singolo neurone.

$$\frac{\partial E}{\partial a_i^{(\ell)}} = \sum_{k=1}^{n_{\ell+1}} \frac{\partial E}{\partial z_k^{(\ell+1)}} \frac{\partial z_k^{(\ell+1)}}{\partial a_i^{(\ell)}}$$

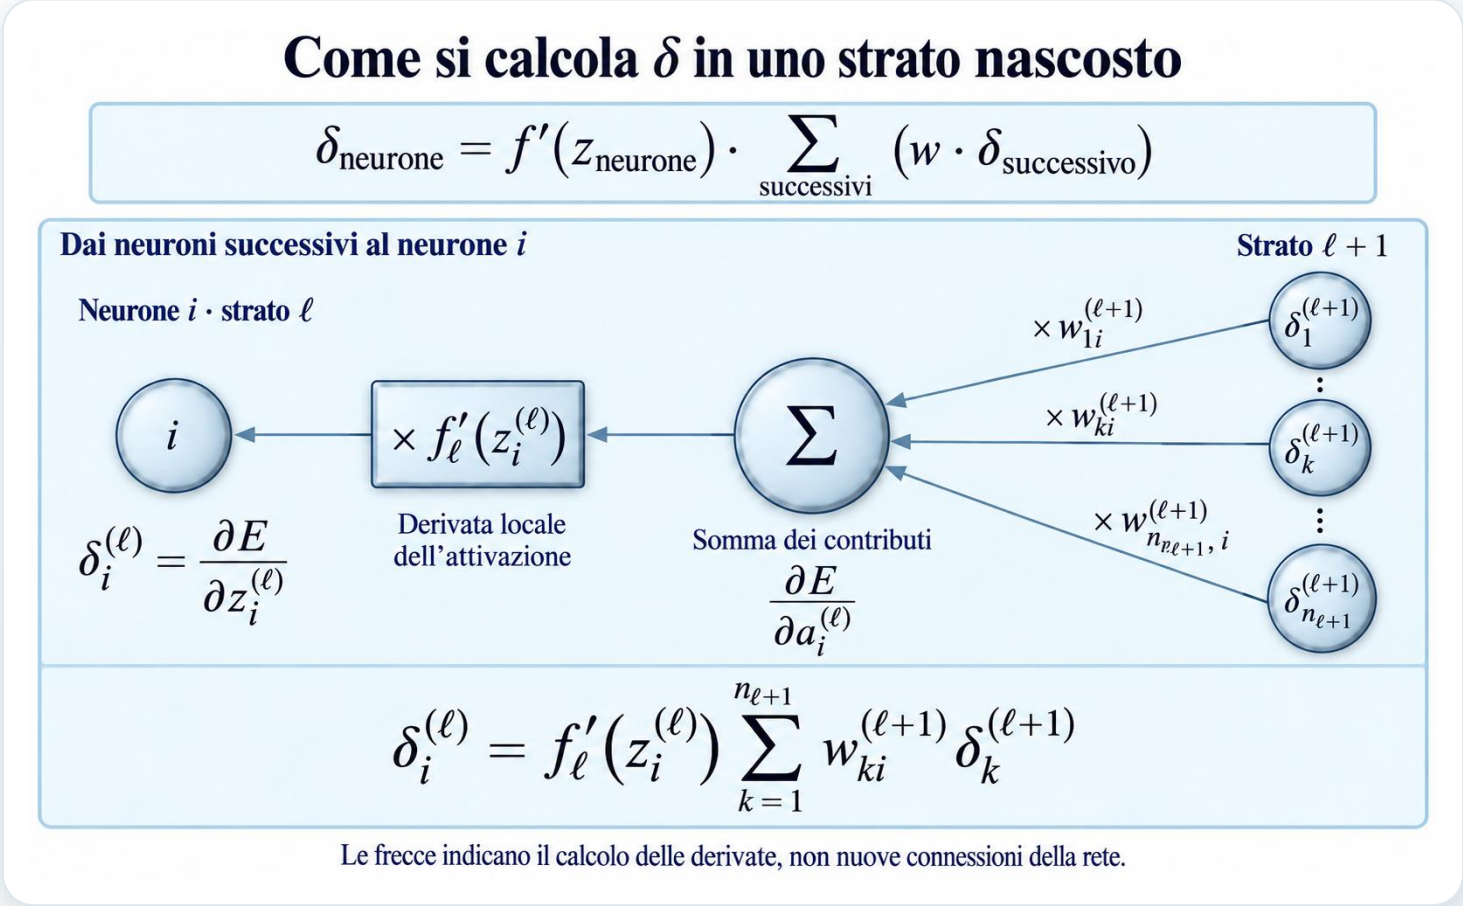
La «regola della catena» multivariata.

$$\delta_i^{(\ell)} = f_\ell'(z_i^{(\ell)}) \sum_{k=1}^{n_{\ell+1}} w_{ki}^{(\ell+1)}\, \delta_k^{(\ell+1)}$$

Il calcolo a partire dallo strato successivo.

Backpropagation: gli strati nascosti

Per attivazioni applicate componente per componente:



Backpropagation: gli strati nascosti

Calcolo diretto all’uscita, poi si procede all’indietro.

$$\delta_{\text{neurone}} = f'(z_{\text{neurone}}) \sum_{\text{successivi}} w \cdot \delta_{\text{successivo}}$$

$$\frac{\partial E}{\partial w} = \delta_{\text{arrivo}} a_{\text{partenza}}, \qquad \frac{\partial E}{\partial b} = \delta_{\text{neurone}}$$

Backpropagation: lo strato di uscita

Sigmoide + errore quadratico.

$$\delta^{(L)} = \frac{\partial E}{\partial z^{(L)}} = (a - y)\, a(1 - a)$$

Softmax + entropia incrociata

Bersaglio one-hot: 1 per la classe corretta c, 0 per le altre.

$$\delta_i^{(L)} = \frac{\partial E}{\partial z_i^{(L)}} = p_i - t_i$$

Verificare una dimostrazione, valutare un testo

Perché l’IA dimostra teoremi complessi ma non scrive capolavori?

La tesi di M. Flora

Riccardo Puglisi · la domanda

«Com’è che l’intelligenza artificiale fa dei capolavori nel provare teoremi difficilissimi e non fa dei capolavori nello scrivere testi letterari?»

Matteo G.P. Flora · la risposta, in tre post

«Perché l’AI dimostra teoremi ma non scrive capolavori? Verificabilità.

1. Matematica: RL con reward verificabile (Lean), milioni di rollout, segnale binario.
2. Letteratura: reward = preferenza umana, rumorosa; ottimizzarla fa collassare l’output sulla moda della distribuzione.»

«Il capolavoro sta nella “coda”: improbabile ma riuscito. Senza verifier, il modello torna al probabile, e il valore letterario non è intrinseco al testo ma relazionale: proxy ottimizzabile ≠ valore. Goodhart in purezza.

Il confine non è mate vs lettere: è verificabile vs giudicabile.»

«Long story short: la prova matematica sta nel metodo. Il capolavoro sta nella interpretazione culturale e/o soggettiva, mai oggettiva.»

Post su X del 10 ottobre 2026 · discussione originale

Verificare una dimostrazione, valutare un testo

La tesi di M. Flora

1. La base comune

Pre-training autoregressivo

I modelli vengono addestrati a calcolare la probabilità del token successivo su enormi quantità di testo.

Una parte della divergenza potrebbe nascere nella fase successiva di Reinforcement Learning (RL) (ottimizzazione dei pesi del modello tramite segnali di ricompensa).

Riccardo Puglisi · la domanda

«Com'è che l'intelligenza artificiale fa dei capolavori nel provare teoremi difficilissimi e non fa dei capolavori nello scrivere testi letterari?»

Matteo G.P. Flora · la risposta, in tre post

«Perché l'AI dimostra teoremi ma non scrive capolavori? Verificabilità.

1. Matematica: RL con reward verificabile (Lean), milioni di rollout, segnale binario.
2. Letteratura: reward = preferenza umana, rumorosa; ottimizzarla fa collassare l'output sulla moda della distribuzione.»

«Il capolavoro sta nella "coda": improbabile ma riuscito. Senza verifier, il modello torna al probabile, e il valore letterario non è intrinseco al testo ma relazionale: proxy ottimizzabile ≠ valore. Goodhart in purezza.

Il confine non è mate vs lettere: è verificabile vs giudicabile.»

«Long story short: la prova matematica sta nel metodo. Il capolavoro sta nella interpretazione culturale e/o soggettiva, mai oggettiva.»

Post su X del 10 ottobre 2026 · discussione originale

Verificare una dimostrazione, valutare un testo

2. Verificabile vs. giudicabile

MATEMATICA

Oggettivamente verificabile → RL su larga scala

Verifica formale esatta

Nei sistemi che utilizzano verificatori formali (es. Lean), una dimostrazione accettata fornisce un segnale di correttezza preciso, che può guidare l'apprendimento per rinforzo.

Rinforzo di soluzioni rare

Il sistema genera milioni di sequenze di calcolo (rollout); la certezza del verificatore permette all'algoritmo di selezionare e consolidare anche percorsi statisticamente improbabili, purché formalmente corretti.

LETTERATURA

Soggettivamente giudicabile → RL su preferenze umane

Segnale rumoroso

La funzione di ricompensa si basa sui voti di valutatori umani, che producono giudizi variabili, dipendenti dai valutatori e dai criteri adottati.

Rischio di convergenza verso moda

Una ricompensa basata sulle preferenze dei valutatori può favorire caratteristiche condivise e ridurre la varietà.

Il capolavoro potrebbe invece essere nella coda della distribuzione: improbabile e magari «divisivo» nelle valutazioni.

Verificare una dimostrazione, valutare un testo

La tesi di M. Flora

È una possibile chiave di lettura, ma resta aperto il problema di quanto le modalità di allenamento spieghino i limiti dei modelli nella scrittura letteraria.

Riccardo Puglisi · la domanda

«Com'è che l'intelligenza artificiale fa dei capolavori nel provare teoremi difficilissimi e non fa dei capolavori nello scrivere testi letterari?»

Matteo G.P. Flora · la risposta, in tre post

«Perché l'AI dimostra teoremi ma non scrive capolavori? Verificabilità.

1. Matematica: RL con reward verificabile (Lean), milioni di rollout, segnale binario.
2. Letteratura: reward = preferenza umana, rumorosa; ottimizzarla fa collassare l'output sulla moda della distribuzione.»

«Il capolavoro sta nella "coda": improbabile ma riuscito. Senza verifier, il modello torna al probabile, e il valore letterario non è intrinseco al testo ma relazionale: proxy ottimizzabile ≠ valore. Goodhart in purezza.

Il confine non è mate vs lettere: è verificabile vs giudicabile.»

«Long story short: la prova matematica sta nel metodo. Il capolavoro sta nella interpretazione culturale e/o soggettiva, mai oggettiva.»

Post su X del 10 ottobre 2026 · discussione originale

↗ Kirk e altri · Generalizzazione e varietà dopo RLHF

Prompt degli agenti · L’incarico

Sei il coordinatore di un piccolo gruppo di lavoro. Obiettivo: una scheda di confronto di UNA pagina tra i sistemi scolastici di Italia, Finlandia e Francia, da presentare a un collegio docenti di liceo.

Organizza il lavoro con 5 sotto-agenti, non di più. **Se non riesci a creare agenti distinti, dichiaralo: non presentare come agenti separati semplici sezioni della stessa risposta**.

Mostra prima il piano (quali agenti crei, cosa fa ciascuno, in che ordine si passano il lavoro), poi eseguilo senza attendere conferme.

Prompt degli agenti · Ricerca

1-3) Tre RICERCATORI, uno per paese, in parallelo. Ciascuno trova solo questi 4 dati, per l'anno più recente disponibile, con il link alla fonte (preferire Eurydice, Eurostat, OCSE):

a. età di inizio e di fine dell'obbligo di istruzione

b. giorni di lezione annui nella secondaria superiore

c. retribuzione statutaria lorda annua INIZIALE, in euro, di un docente di secondaria superiore (non lo stipendio medio, non il netto)

d. spesa pubblica per l'istruzione in % del PIL

Ogni ricercatore restituisce solo una tabella con dato, anno e fonte. Massimo 3 ricerche per dato. **Se un dato non si trova, scrivi "non reperito": niente stime inventate**.

Prompt degli agenti · Verifica e correzione

4) Un VERIFICATORE, che non ha partecipato alla ricerca: apre le fonti citate, controlla ogni numero e prepara segnalazioni indirizzate al ricercatore del paese interessato. Distingue gli errori veri dai limiti di confrontabilità (un anno diverso non è di per sé un errore). **Se una fonte non è accessibile, lo dichiara**.

CICLO DI CORREZIONE: tu, coordinatore, inoltri a ciascun ricercatore solo le segnalazioni che lo riguardano. Il ricercatore corregge il dato con una nuova fonte oppure difende il dato originale spiegando perché. Il verificatore assegna a ogni dato contestato uno stato finale: verificato, corretto, non verificabile, non comparabile. Un solo giro di correzione.

Prompt degli agenti · Analisi e consegna

5) Un ANALISTA, dopo il ciclo di correzione: crea un file Excel con i dati definitivi e il loro stato, e due grafici a barre separati (retribuzione iniziale in euro; spesa in % del PIL). I dati mancanti non vanno mostrati come zero.

Infine tu, coordinatore, componi un documento Word con:

a. tabella con i dati definitivi
b. i due grafici
c. tre osservazioni (massimo 150 parole in tutto)
d. elenco delle fonti
e. un riquadro "Il dialogo tra agenti" con, per ogni dato contestato: segnalazione → risposta del ricercatore → decisione finale. Riporta solo scambi realmente avvenuti, senza ricostruire dialoghi.
f. in chiusura: quali dati restano incerti e quali verifiche umane servirebbero.

Un esempio di incarico al redattore

Vorrei preparare una dispensa dettagliata per i miei alunni di quarta liceo scientifico sul gioco del superenalotto.

Nella dispensa devi spiegare come funziona il gioco, calcolare, con tutti i passaggi di calcolo combinatorio chiari e dettagliati e motivati, la probabilità di fare 6, 5+1, 5 e poi elencare i valori di tutte le altre probabilità di vincita.

Devi spiegare che è un gioco statisticamente iniquo, mostrare la rendita media di ogni tipologia di vincita, fare alcuni paragoni tra la probabilità di vincere il jackpot e quella di altri fenomeni.
Indica sempre le fonti dei dati che utilizzi. Puoi aggiungere alla dispensa qualsiasi cosa tu ritenga utile oltre al mio elenco. Per l'output, scegli il formato di file per te più veloce da gestire.

Il passaggio fra redattore e revisore

Al revisore

«Revisiona impostazione, comprensibilità, calcoli e fonti della dispensa. Prepara un report con le modifiche che proponi.»

Al redattore

«Valuta i suggerimenti, modifica ciò che ritieni necessario e prepara una risposta motivata al revisore.»

Di nuovo al revisore

«Esamina la versione aggiornata e la risposta. Segnala ciò che resta da correggere.»

Bibliografia

Testi per approfondire

Artificial Intelligence: A Modern Approach
Russell · Norvig · Pearson

Deep Learning with Python
Chollet · Manning

Deep Learning
Goodfellow · Bengio · Courville · MIT Press

Grokking Deep Learning
Trask · Manning

Deep Learning for NLP and Speech Recognition
Kamath · Liu · Whitaker · Springer

Understanding Machine Learning: From Theory to Algorithms
Shalev-Shwartz · Ben-David · Cambridge University Press

Deep Learning in Science
Baldi · Cambridge University Press

What Is ChatGPT Doing … and Why Does It Work?
Wolfram · Wolfram Media